

1. Fontes de Dados



catalogo.csv
Produtos e metadados



comentarios.json
Avaliações textuais



interacoes.json
Interações dos usuários

2. Pipeline de Ingestão



Leitura dos arquivos



Validação de schema,
tipos e campos obrigatórios

Dados inválidos



Registros rejeitados
e resumo da ingestão

Dados
válidos



Limpeza e padronização
de textos, IDs e datas

Produtos e dados
normalizados

3. Dados Semiestruturados



MongoDB
comentários e interações
processados

Comentários e interações

4. Embeddings e Busca Semântica



Geração de embeddings
para textos e produtos



PostgreSQL + pgvector
embeddings e índices
vetoriais



Busca por similaridade
de vetores

5. Processamento e Recomendação



Motor de recomendação
combina similaridade,
interações e regras



Lista de recomendações
por usuário



PostgreSQL
produtos, usuários,
interações consolidadas
e recomendações

6. Apresentação



Apache Superset
dashboards e indicadores

Visualização dos dados,
acompanhamento de métricas,
recomendações e insights
para os usuários.